



Universidad Tecnológica de Bolívar

UNIVERSIDAD TECNOLÓGICA DE BOLÍVAR

Análisis exploratorio del dataset Diamonds con RStudio

Estudiantes:

German De Armas - Angel Vega
Juan Luis Ochoa - Laura Gonzalez

Profesor:

Carlos Ferreira

February 19, 2026

Contents

1	Introducción	2
2	Análisis gráfico de valores faltantes (NA)	2
3	Análisis gráfico de densidad	3
3.1	Concentración de datos (Densidad visual)	3
3.2	Distribución del corte (Cut)	3
3.3	Intersección de Atributos	4
4	Boxplot de Claridad vs Precios	4
4.1	Paradoja de Claridad vs. Precio	4
4.2	Distribución y Dispersión	5
4.3	Frecuencia y Representatividad	5
5	Boxplot de la distribución del precio por categoría de color	5
6	Análisis de Histograma de Quilataje (Carat)	6
7	Análisis de scatter plot de distribución entre Quilataje y Precio	7
8	Análisis de Matriz de correlación	8
9	Análisis de Pareto nivel 1 (calidad del corte, claridad y color)	9
10	Análisis de Boxplot del Precio según Color y Tipo de corte	10
11	Análisis de Pareto nivel 2 (calidad del corte, claridad y color)	11

1 Introducción

El presente documento se centra en la interpretación y el análisis de las representaciones gráficas derivadas del conjunto de datos Diamonds, tras un proceso de limpieza y refinamiento de la información. El objetivo principal es identificar visualmente las correlaciones y distribuciones de variables críticas como el quilataje, el precio y las categorías de calidad (corte, color y claridad). A través de herramientas visuales como histogramas de distribución, diagramas de dispersión y boxplots comparativos, se examina cómo las propiedades físicas influyen en la valoración económica de los diamantes. Adicionalmente, se integra un análisis de Pareto de múltiples niveles para determinar la frecuencia y dominancia de ciertos atributos de calidad, permitiendo una comprensión profunda de la composición de la muestra analizada.

2 Análisis gráfico de valores faltantes (NA)




Figure 1: Observaciones vs variables analizadas

El gráfico evidencia que el 100% de las observaciones del dataset Diamonds se encuentran completas, confirmando la ausencia de valores faltantes (NA) en todas las variables analizadas.

3 Análisis gráfico de densidad




Figure 2: Número de diamantes por tipo, corte, color y claridad

El gráfico analizado es una representación visual que permite observar la distribución y densidad de las 53,775 observaciones del dataset tras su limpieza. A continuación, se presenta el análisis detallado de dicha visualización:

3.1 Concentración de datos (Densidad visual)

- **Claridad y Color:** La mayor densidad de diamantes (representada por el tamaño de los círculos en la cuadrícula) se concentra en las claridades SI1, VS2 y SI2, especialmente en los colores G, F y E. Esto coincide con los análisis de Pareto, donde la claridad SI1 es la más frecuente (24.23%) y el color G lidera su categoría (20.92%).
- **Zonas de escasez:** Se observa una presencia mínima de diamantes en la claridad IF (Internally Flawless) y en el color J, representados por círculos significativamente más pequeños o casi inexistentes en los extremos de la gráfica. Según los datos, la claridad IF solo representa el 3.31% del total.

3.2 Distribución del corte (Cut)

- **Dominancia del corte "ideal":** En casi todas las combinaciones de color y claridad, el color amarillo (que representa el corte Ideal) ocupa la mayor porción de cada círculo. Esto es consistente con el hecho de que el corte Ideal es el más común en el dataset, representando casi el 40% de la muestra (21,485 diamantes).
- **Cortes de menor frecuencia:** Los cortes Fair (púrpura) y Good (azul oscuro) muestran las proporciones más delgadas dentro de los sectores circulares, lo cual se valida con el análisis de Pareto donde el corte Fair apenas alcanza el 2.97% de los datos,.

3.3 Intersección de Atributos

- **Calidad vs. Cantidad:** La gráfica permite visualizar que, a medida que aumenta la calidad de la claridad (hacia la derecha en el eje X, de I1 a IF), el número total de diamantes disminuye drásticamente, independientemente del color.
- **Uniformidad del Corte:** Es notable que, incluso en diamantes de menor calidad cromática (colores I y J), el corte Ideal sigue siendo el predominante, sugiriendo que el esfuerzo de producción se centra en maximizar el brillo (corte) incluso si la materia prima tiene impurezas o coloración. En resumen, el gráfico revela un mercado donde predominan los diamantes con cortes de alta calidad (Ideal y Premium) pero con características de claridad y color intermedias (SI1-VS2 y E-G), mientras que las piezas con pureza máxima (IF) son extremadamente raras.

4 Boxplot de Claridad vs Precios




Figure 3: Boxplot Puntuación de claridad vs Precios

El análisis del Boxplot de precio por calificación de claridad revela una tendencia contraintuitiva pero explicable dentro del mercado de diamantes representado en los datos. A continuación, se detallan los hallazgos principales basados en la visualización:

4.1 Paradoja de Claridad vs. Precio

- **Relación inversa:** Se observa que, a medida que la claridad mejora (avanzando de I1 hacia IF en el eje X), el precio mediano tiende a disminuir. Mientras que los diamantes de menor claridad como SI2 muestran la mediana de precio más alta (cercana a los \$4,000), los diamantes de máxima pureza (IF) tienen una mediana significativamente más baja (cercana a los \$1,000).
- **Influencia del Quilataje:** Esta tendencia sugiere que los diamantes con claridades superiores en este dataset suelen ser de menor tamaño (quilataje), mientras que los

diamantes de claridades bajas compensan su falta de pureza con un mayor tamaño para alcanzar precios de mercado más altos.

4.2 Distribución y Dispersión

- **Rango Intercuartílico (IQR):** Las categorías de claridad SI2, SI1, VS2 y VS1 muestran cajas más amplias, lo que indica una mayor variabilidad en los precios dentro de estos grupos. En contraste, las categorías de alta pureza (VVS1, IF) tienen cajas muy compactas cerca de la base, lo que refleja que la gran mayoría de estos diamantes se comercializan en rangos de precios bajos y uniformes en esta muestra.
- **Valores Atípicos (Outliers):** Todas las categorías, sin excepción, presentan una densa cantidad de valores atípicos que se extienden hasta el precio máximo registrado (cercano a los \$18,823). Esto demuestra que, independientemente de la claridad, existen diamantes que alcanzan valores premium debido a la combinación excepcional de otros factores como el corte o el tamaño.

4.3 Frecuencia y Representatividad

- **Dominancia del Mercado:** Es importante notar que las claridades con precios medianos más altos, como SI1 (24.23%) y VS2 (22.73%), son también las más frecuentes en el dataset según el análisis de Pareto. La claridad IF, a pesar de su prestigio, es escasa (3.31%) y se concentra en piezas pequeñas de menor costo total.

En conclusión, el boxplot demuestra que la claridad por sí sola no garantiza un precio mayor; el valor económico está fuertemente condicionado por la distribución del quilataje en cada categoría de pureza.

5 Boxplot de la distribución del precio por categoría de color




Figure 4: Boxplot de Precios vs Rating de color

- **Tendencia Ascendente del Precio Mediano:** Se observa que las categorías de color con menor grado de pureza cromática (como J e I) presentan las medianas de precio más altas del dataset. En contraste, los colores considerados "superiores" (D, E y F) muestran medianas de precio significativamente más bajas.
- **Dispersión y Variabilidad:** Los diamantes de color J, I y H poseen los rangos intercuartílicos más amplios, lo que indica una mayor incertidumbre o variedad en sus precios de mercado. Las categorías D y E presentan cajas más compactas, concentrando la mayoría de sus observaciones en el segmento de precios bajos.
- **Persistencia de Valores Atípicos:** Independientemente de la calificación de color, todas las categorías muestran una alta densidad de outliers que se extienden hasta el techo de los \$18,823. Esto sugiere que piezas excepcionales en quilataje o corte pueden alcanzar precios máximos sin importar su coloración.
- **Representatividad:** Representatividad: El color G es el más frecuente en la muestra (20.9%), manteniendo una posición central tanto en frecuencia como en distribución de costos.

6 Análisis de Histograma de Quilataje (Carat)




Figure 5: Boxplot de Precios vs Rating de color

El análisis del Histograma de quilataje (Carat) revela la distribución física de la muestra y las tendencias de comercialización en la industria:

- **Sesgo a la Derecha:** La distribución presenta un marcado sesgo positivo, lo que indica que la gran mayoría de los diamantes son de tamaño pequeño, concentrándose principalmente entre los 0.2 y 1.0 quilates.
- **Picos de Pesos Comerciales:** Se observan incrementos abruptos de frecuencia en valores "redondos" como 0.3, 0.5, 0.7, 1.0 y 1.5 quilates. Esto sugiere que los talladores priorizan alcanzar estos pesos estándar debido a su mayor demanda y valor en el mercado.

- **Métricas Clave:** La mayor densidad de la muestra se sitúa por debajo de la mediana de 0.70 quilates, con un primer cuartil que se ubica en los 0.40 quilates.
- **Escasez de Piedras Grandes:** Por encima de los 2.0 quilates, la cantidad de diamantes disminuye drásticamente, convirtiendo a los ejemplares cercanos al máximo de 5.01 quilates en observaciones excepcionales dentro del dataset.

7 Análisis de scatter plot de distribución entre Quilataje y Precio



Figure 6: Relación entre quilates y precio con diferenciación por tipo de corte

El análisis del Scatter plot de quilates y precio revela la relación más crítica del dataset:

- **Correlación Positiva Intensa:** Existe una relación directa y fuerte entre el tamaño y el valor; a medida que aumenta el quilataje, el precio se incrementa de forma exponencial, no lineal.
- **Dispersión por Calidad:** Para un mismo peso (ej. 1.0 quilate), existe una amplia variación de precios. Los puntos coloreados indican que los cortes Ideal y Premium se posicionan sistemáticamente en la parte superior de los rangos de precio para cada nivel de quilataje.
- **Concentración en Pesos Comerciales:** Se observan densas franjas verticales en valores "redondos" (1.0, 1.5 y 2.0 quilates), lo que confirma que los diamantes son tallados específicamente para alcanzar estos umbrales comerciales de mayor demanda.
- **Variabilidad en Piedras Grandes:** A partir de los 2.0 quilates, la dispersión aumenta significativamente, sugiriendo que en diamantes de gran tamaño, factores como el color y la claridad tienen un impacto aún más determinante en el precio final.

8 Análisis de Matriz de correlación





Figure 7: Matriz de correlación

El análisis de la matriz de correlación permite identificar los factores que realmente mueven el valor de mercado de los diamantes. A continuación se presentan las conclusiones más importantes del estudio: El análisis de correlación confirma que el quilataje (carat) es el principal determinante del precio, evidenciando una relación positiva muy fuerte: a mayor tamaño del diamante, mayor es su valor. En contraste, la claridad y el color presentan una correlación negativa con el precio en este dataset, fenómeno explicado por la distribución del tamaño de las piedras dentro de estas categorías. Por su parte, el corte muestra una relación positiva pero débil en comparación con el quilataje, lo que indica que su influencia en el precio es secundaria frente a las dimensiones físicas del diamante. Asimismo, se observa una correlación casi perfecta entre el quilataje y las variables de dimensión, lo que respalda la coherencia y calidad de los datos analizados.


En conclusión, la matriz de correlación establece que el quilataje es el motor principal del precio, mientras que la claridad y el color actúan como variables que, en este conjunto de datos específico, están inversamente relacionadas con el precio debido a su distribución respecto al tamaño de las piezas.

9 Análisis de Pareto nivel 1 (calidad del corte, claridad y color)




Pareto Calidad del corte

- **Dominancia del corte ideal:** categoría más frecuente con 21,485 unidades, representando por sí sola el 39.95% del total.
- **Concentración de calidad:** Los cortes de alta calidad (Ideal y Premium) acumulan el 65.5% de la muestra, mientras que el corte de menor calidad (Fair) es casi inexistente con apenas un 2.97%.



Pareto Niveles de claridad

- **Prevalencia de grados intermedios:** La claridad SI1 lidera con un 24.23%, seguida de cerca por VS2 con un 22.73%.
- **Distribución de pureza:** Los cuatro primeros niveles (SI1, VS2, SI2 y VS1) representan el 79.1% de los diamantes, dejando a las categorías extremas como IF (máxima pureza) e I1 (mínima pureza) con frecuencias muy bajas (3.3% y 1.3% respectivamente).



Pareto Color

- **Liderazgo del color G:** Es el atributo más común con 11,254 unidades (20.92%), seguido por los colores E (18.17%) y F (17.69%).
- **Sesgo hacia la ausencia de color:** Existe una distribución más equilibrada entre los primeros cinco niveles (G, E, F, H, D), los cuales cubren el 84.7% de los datos, mientras que el color J (el más amarillento) es el menos frecuente con un 5.21%.

Figure 8: Análisis comparativo de los diagramas de Pareto aplicados al dataset Diamonds

10 Análisis de Boxplot del Precio según Color y Tipo de corte de corte




Figure 9: Boxplot del precio según color y tipo de corte





Figure 10: Boxplot Analysis – Mind Map


11 Análisis de Pareto nivel 2 (calidad del corte, claridad y color)

Análisis del Diagrama de Pareto: Color dentro de Corte Ideal




- El color G domina la frecuencia: G es el color más frecuente en diamantes de corte Ideal, superando notablemente a los demás. Junto con E y F, estos tres colores concentran aproximadamente el 50% acumulado de los diamantes Ideal, lo que sugiere que el mercado prefiere o produce más diamantes Ideal en rangos de color medio-alto.
- La distribución es relativamente uniforme: El principio de Pareto no se evidencia en este caso. A diferencia de un comportamiento típico —donde el 20% de las categorías concentra el 80% de los casos—, la curva acumulada presenta un crecimiento gradual y sostenido. Esto indica que ninguna categoría de color domina de manera significativa; por el contrario, todas contribuyen de forma relativamente equilibrada a la frecuencia total, con J como la única que muestra un rezago evidente.

Análisis del Diagrama de Pareto: Color dentro de Corte Premium



Distribución relativamente equilibrada: Dentro de la categoría Premium, ningún color concentra de manera dominante la frecuencia total; la curva acumulada crece de forma progresiva, lo que indica una distribución bastante homogénea entre categorías. El color G presenta la mayor frecuencia, mientras que J muestra la menor participación, evidenciando una diferencia clara entre el primer y el último lugar en contribución.

Análisis del Diagrama de Pareto: Color dentro de Corte Fair



- G, F y H concentran cerca del 50% de los diamantes Fair. A diferencia de Premium e Ideal, aquí se observa una leve mayor concentración en los primeros tres colores (G, F, H). La curva acumulada tiene una pendiente inicial más pronunciada que en los cortes anteriores, acercándose un poco más al comportamiento Pareto, aunque sin llegar a cumplirlo plenamente.
- Los colores "extremos" son los menos frecuentes en Fair: Tanto D (mejor color) como J (peor color) son los menos representados en el corte Fair. Esto sugiere que en el mercado de diamantes con corte justo, se evita combinar este corte con los colores más extremos — posiblemente porque un diamante D-Fair sería comercialmente poco atractivo, y un J-Fair representaría la combinación de menor calidad posible.